Relatório de Visão Computacional

Classificação de Células Cervicais para Detecção de Lesões Pré-Cancerosas Utilizando YOLOv8

Marcelo de Araújo
Repositório do Projeto

8 de março de 2026

Sumário

1 Introdução **3**
1.1 Objetivos . . . 3

2 Conjunto de Dados **3**
2.1 Origem e Obtenção . . . 3
2.2 Estrutura e Distribuição . . . 3
2.3 Pré-processamento e Organização para YOLOv8 . . . 4
2.4 Divisão dos Dados . . . 5

3 Fluxo Completo da Solução **5**

4 Arquitetura do Modelo: YOLOv8 Classify **6**
4.1 Backbone: CSPDarknet . . . 6
4.2 Classificador . . . 6
4.3 *Transfer Learning* . . . 7
4.4 Parâmetros de Treinamento . . . 7

5 Métricas de Avaliação **7**
5.1 Acurácia . . . 8
5.2 Precisão . . . 8
5.3 Revocação (Sensibilidade) . . . 8
5.4 F1-Score . . . 8
5.5 Especificidade . . . 8
5.6 Matriz de Confusão . . . 9

6 Ajuste de Hiperparâmetros **9**
6.1 Experimentos Realizados . . . 9
6.2 Justificativa das Variações . . . 9
6.3 Resultados da Variação — Classificação Binária . . . 10
6.4 Resultados da Variação — Classificação Multiclasse . . . 11

7 Resultados **12**
7.1 Experimento 1: Classificação Binária (Normal vs. Anormal) 12
7.2 Experimento 2: Classificação Multiclasse (6 Doenças) 15
7.3 Comparação entre os Experimentos 21

8 Discussão **21**
8.1 Desempenho do YOLOv8 como Classificador 21
8.2 Impacto do Desbalanceamento 21
8.3 Confusões Clinicamente Relevantes 21
8.4 Limitações 22

9 Implementação **22**
9.1 Bibliotecas Utilizadas 22

10 Conclusão **23**

1 Introdução

O presente trabalho aborda um problema de visão computacional que consiste na **classificação automática de imagens de células cervicais** provenientes do exame de Papanicolaou. O objetivo principal é auxiliar na detecção de lesões pré-cancerosas e cancerosas do colo do útero por meio de técnicas de aprendizado profundo.

O câncer de colo do útero constitui uma das principais causa de óbito por neoplasias malignas entre mulheres em escala global. O exame citopatológico de Papanicolaou é o método de triagem mais amplamente utilizado na prática clínica, entretanto a análise manual das lâminas caracteriza-se por ser um processo demorado e sujeito a variabilidade inter-observador. A automação deste processo através de modelos de aprendizado profundo possibilita aumentar tanto a velocidade quanto a consistência dos diagnósticos.

Neste projeto, foi utilizado o modelo **YOLOv8** (*You Only Look Once*, versão 8) da Ultralytics no modo de classificação de imagens (*classify*). Embora o YOLO seja tradicionalmente reconhecido como um detector de objetos em tempo real, a versão 8 incorpora um módulo de classificação que permite o seu emprego como classificador de imagens, constituindo uma alternativa as redes convolucionais tradicionais.

1.1 Objetivos

Foram definidos dois objetivos complementares para o projeto:

1. **Classificação binária:** Distinguir entre células *Normais* e *Anormais*, proporcionando uma triagem inicial rápida para encaminhamento clínico.

2. **Classificação multiclasse:** Classificar as células em 6 categorias diagnósticas específicas — Negativa, ASC-US, LSIL, ASC-H, HSIL e Carcinoma — permitindo a identificação do tipo exato da lesão celular.

2 Conjunto de Dados

2.1 Origem e Obtenção

O conjunto de dados utilizado neste trabalho são composto por imagens de células cervicais no formato TIFF (*Tagged Image File Format*), obtidas a partir de exames citopatológicos de Papanicolaou. As imagens possuem dimensões de 50×50 pixels em 3 canais de cor (RGB).

Fonte do dataset: O conjunto de imagens foi fornecido diretamente por um professor da universidade, sendo composto por amostras citológicas cervicais organizadas e rotuladas para fins didáticos e de pesquisa acadêmica.

2.2 Estrutura e Distribuição

O dataset encontra-se organizado em subpastas dentro do diretório `cells/`, onde cada subpasta corresponde a uma categoria diagnóstica conforme o Sistema Bethesda para classificação citológica cervical. A Tabela 1 apresenta a distribuição completa das amostras.

Tabela 1: Distribuição das classes no dataset utilizado.

Subpasta	**Diagnóstico**	**Imagens**	**Classe Binária**
Negativa	Negativo para lesão intraepitelial	5.500	Normal
ASC-US	Cél. escamosas atípicas de signif. indeterminado	620	Anormal
LSIL	Lesão intraepitelial escamosa de baixo grau	1.300	Anormal
ASC-H	Cél. escamosas atípicas, não excluindo HSIL	910	Anormal
HSIL	Lesão intraepitelial escamosa de alto grau	1.680	Anormal
Carcinoma	Carcinoma de células escamosas	120	Anormal
Total		**10.130**	—

Observa-se a presença de um **desbalanceamento significativo** entre as classes. A classe Negativa concentra 54,3% do total de amostras, enquanto a classe Carcinoma representa apenas 1,2% do conjunto. Este cenário é condizente com a distribuição esperada em contextos clínicos reais, onde casos normais são majoritários.

2.3 Pré-processamento e Organização para YOLOv8

O modelo YOLOv8 no modo *classify* requer que os dados estejam organizados em uma estrutura hierárquica de diretórios com subpastas `train/` e `val/`. Desta forma, o pré-processamento envolveram as seguintes etapas:

1. **Coleta dos caminhos:** Todos os arquivos de imagem (`.tif`) foram percorridos recursivamente nas subpastas do diretório `cells/`, associando cada imagem ao rótulo correspondente da sua subpasta de origem.

2. **Divisão estratificada:** O conjunto foi particionado em treino (80%) e validação (20%) utilizando a função `train_test_split` do scikit-learn com os parâmetros `random_state=42` e `stratify=labels`, garantindo que a proporção de cada classe fosse mantido em ambos os subconjuntos.

3. **Reorganização dos diretórios:** As imagens foram copiadas para a nova estrutura de pastas exigida pelo YOLOv8:

Para a classificação **binária**, as 6 subpastas originais foram agrupadas em duas classes:

```
dataset_yolo_binario/
 train/
    Normal/      (imagens da subpasta Negativa)
    Anormal/     (imagens de ASC-US, LSIL, ASC-H, HSIL, carcinoma)
 val/
     Normal/
     Anormal/
```

Para a classificação **multiclasse**, cada subpasta original foi preservada:

```
dataset_yolo_doencas/
 train/
    ASC-H/   ASC-US/   HSIL/
```

```
    LSIL/    Negativa/   carcinoma/
val/
    (mesmas 6 subpastas)
```

A normalização das imagens e o redimensionamento são realizadas automaticamente pelo YOLOv8 durante o treinamento, não necessitando de tratamento manual.

2.4 Divisão dos Dados

Tabela 2: Divisão do dataset em treinamento e validação.

Conjunto	**Proporção**	**Imagens (aprox.)**
Treinamento	80%	8.104
Validação	20%	2.026
Total	100%	10.130

3 Fluxo Completo da Solução

A Figura 1 apresenta o diagrama esquemático do fluxo completo implementado neste trabalho, aplicável a ambos os experimentos (binário e multiclasse).

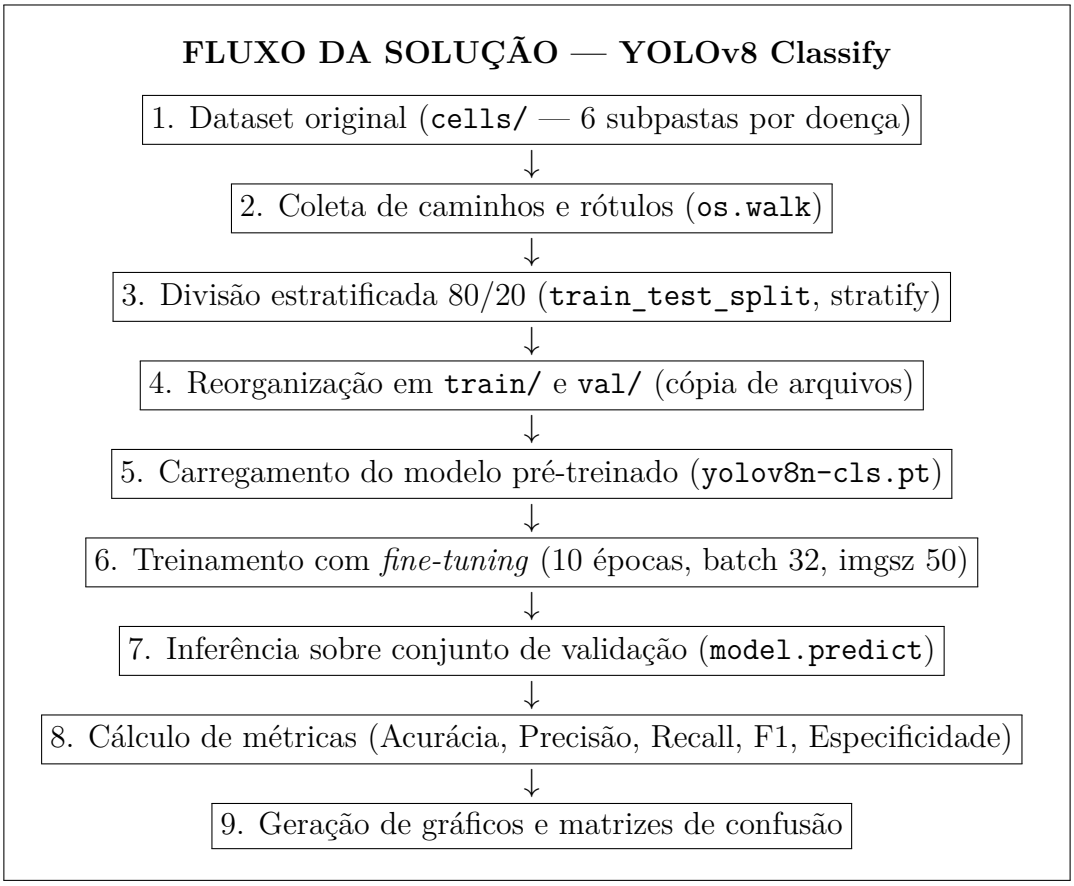

Figura 1: Fluxo completo da solução proposta utilizando YOLOv8 no modo *classify*.

4 Arquitetura do Modelo: YOLOv8 Classify

O YOLO (*You Only Look Once*) é uma família de modelos de aprendizado profundo originalmente projetados para detecção de objetos em tempo real. A versão 8, desenvolvida pela Ultralytics, expandiu as capacidades do framework para incluir tarefas de **classificação de imagens**, além da detecção e segmentação. Esta seção detalham o funcionamento do YOLOv8 no modo *classify*, uma vez que esta abordagem não é tipicamente abordada em disciplinas convencionais de visão computacional.

4.1 Backbone: CSPDarknet

O extrator de características (*backbone*) do YOLOv8 é baseado em uma versão modificada do **CSPDarknet** (*Cross-Stage Partial Darknet*). Diferentemente de uma CNN sequencial simples, o CSPDarknet emprega conexões parciais entre estágios (*Cross-Stage Partial connections*), que dividem o fluxo de gradientes em dois caminhos distintos. Esta estratégia reduz a redundância computacional e melhora o aprendizado de características, permitindo que a rede aprenda representações mais rica com menos parâmetros.

O backbone aplica sucessivas operações de **convolução**, **normalização por lote** (*batch normalization*) e ativação **SiLU** (*Sigmoid Linear Unit*):

$$\mathrm{SiLU}(x) = x \cdot \sigma(x) = \frac{x}{1 + e^{-x}} \tag{1}$$

onde $\sigma(x)$ é a função sigmoide. A SiLU é uma função de ativação suave e não-monótona que tende a apresentar melhor desempenho que a ReLU em redes profundas.

4.2 Classificador

Após a extração de características pelo backbone, o módulo de classificação do YOLOv8 aplica:

1. **Global Average Pooling (GAP):** Reduz cada mapa de características a um único valor escalar, calculando a média de todos os elementos espaciais:

$$z_k = \frac{1}{H \times W} \sum_{i=1}^{H} \sum_{j=1}^{W} f_k(i, j) \tag{2}$$

   onde $f_k(i, j)$ é o valor do k-ésimo mapa de características na posição (i, j), e $H \times W$ são as dimensões espaciais.

2. **Camada Linear (*Fully Connected*):** Mapeia o vetor de características para o espaço de K classes, produzindo os logits de saída.

3. **Softmax:** Converte os logits em probabilidades normalizadas:

$$P(y = c \mid \mathbf{x}) = \frac{e^{z_c}}{\sum_{j=1}^{K} e^{z_j}} \tag{3}$$

4.3 *Transfer Learning*

Uma das principais vantagem do YOLOv8 em relação a CNNs construídas do zero é a utilização de ***transfer learning*** (aprendizado por transferência). O modelo base `yolov8n-cls.pt` (variante *nano*) é disponibilizado com pesos pré-treinados no dataset **ImageNet**, que contém aproximadamente 1,2 milhão de imagens distribuídas em 1.000 classes.

O processo de *transfer learning* consiste em:

1. Carregar os pesos pré-treinados, que já codificam conhecimento sobre extração de bordas, texturas, formas e padrões visuais genéricos.

2. Substituir a camada de classificação final para adequar o número de saídas ao problema específico (2 classes no binário, 6 no multiclasse).

3. Realizar o *fine-tuning* (ajuste fino) dos pesos em todo o modelo utilizando o dataset de células cervicais.

Esta abordagem é particularmente vantajosa para datasets de tamanho reduzido ou com desbalanceamento entre classes, pois os pesos iniciais já possuem uma boa representação de características visual de baixo e médio nível.

4.4 Parâmetros de Treinamento

A Tabela abaixo resume os hiperparâmetros utilizados nos experimentos de treinamento.

Tabela 3: Hiperparâmetros de treinamento do YOLOv8.

Parâmetro	**Valor**
Modelo base	`yolov8n-cls.pt` (nano)
Tamanho da imagem	50×50 pixels
Épocas	10
Tamanho do *batch*	32
Dispositivo	Apple MPS (Metal Performance Shaders)
Otimizador	SGD com momentum (padrão Ultralytics)
Função de perda	Cross-Entropy
Validação por época	Sim (`val=True`)
Pesos iniciais	Pré-treinados no ImageNet

5 Métricas de Avaliação

Para avaliar quantitativamente o desempenho dos modelos, foram empregadas as métricas descritas a seguir. Todas as métricas foram calculados utilizando a biblioteca scikit-learn a partir das predições do modelo sobre o conjunto de validação.

5.1 Acurácia

A acurácia corresponde à proporção de predições corretas em relação ao total de amostras avaliadas:

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN} \tag{4}$$

onde VP = verdadeiros positivos, VN = verdadeiros negativos, FP = falsos positivos e FN = falsos negativos.

5.2 Precisão

A precisão (*precision*) quantifica a proporção de verdadeiros positivos dentre todas as predições positivas realizadas pelo modelo:

$$\text{Precisão} = \frac{VP}{VP + FP} \tag{5}$$

5.3 Revocação (Sensibilidade)

A revocação (*recall*) mede a capacidade do modelo de identificar corretamente todas as amostras positivas:

$$\text{Revocação} = \frac{VP}{VP + FN} \tag{6}$$

No contexto clínico, a revocação é particularmente relevante, pois um falso negativo (lesão não detectada) pode ter consequências graves para a paciente.

5.4 F1-Score

O F1-Score constitui a média harmônica entre a precisão e a revocação, fornecendo uma medida balanceada entre ambas:

$$F_1 = 2 \cdot \frac{\text{Precisão} \times \text{Revocação}}{\text{Precisão} + \text{Revocação}} \tag{7}$$

Na avaliação multiclasse, foi utilizada a versão *weighted*, na qual o F1-Score de cada classe é ponderada pelo número de amostras daquela classe:

$$F_{1,\text{weighted}} = \sum_{c=1}^{K} \frac{n_c}{N} \cdot F_{1,c} \tag{8}$$

onde n_c é o número de amostras da classe c e N o total de amostras.

5.5 Especificidade

A especificidade avalia a capacidade do modelo em identificar corretamente as amostras negativas:

$$\text{Especificidade} = \frac{VN}{VN + FP} \tag{9}$$

Para o cenário multiclasse, a especificidade foram calculada individualmente para cada classe c utilizando a abordagem *one-vs-rest*:

$$\text{Especificidade}_c = \frac{VN_c}{VN_c + FP_c} \tag{10}$$

onde $VN_c = \sum_{i \neq c} \sum_{j \neq c} M_{i,j}$ e $FP_c = \sum_{i \neq c} M_{i,c}$, sendo M a matriz de confusão.

5.6 Matriz de Confusão

A matriz de confusão M de dimensão $K \times K$ sumariza a distribuição das predições em relação aos rótulos verdadeiros. O elemento $M_{i,j}$ indica a quantidade de amostras pertencentes à classe i que foi classificada como pertencente à classe j. Os elementos na diagonal principal ($M_{i,i}$) representam as classificações corretas.

6 Ajuste de Hiperparâmetros

O ajuste de hiperparâmetros foi conduzido de forma sistemática, variando individualmente quatro hiperparâmetros distintos — número de épocas, tamanho do *batch*, taxa de aprendizado e variante do modelo — enquanto os demais permaneciam fixos. Esta abordagem de variação controlada permite isolar o efeito de cada hiperparâmetro sobre o desempenho do modelo. Os experimentos foram executados tanto para a classificação binária quanto para a multiclasse.

6.1 Experimentos Realizados

A Tabela abixo apresenta a configuração completa dos 8 experimentos conduzidos para cada cenário de classificação:

Tabela 4: Configuração dos experimentos de variação de hiperparâmetros.

Experimento	**Modelo**	**Épocas**	**Batch**	**LR**	**Variável**
base	yolov8n-cls	10	32	0,01	— (referência)
epochs_5	yolov8n-cls	5	32	0,01	Épocas
epochs_20	yolov8n-cls	20	32	0,01	Épocas
batch_16	yolov8n-cls	10	16	0,01	Batch size
batch_64	yolov8n-cls	10	64	0,01	Batch size
lr_0001	yolov8n-cls	10	32	0,001	Learning rate
lr_005	yolov8n-cls	10	32	0,05	Learning rate
modelo_s	yolov8s-cls	10	32	0,01	Arquitetura

6.2 Justificativa das Variações

- **Número de épocas (5, 10, 20):** Avalia se o modelo converge adequadamente com menos treinamento ou se beneficia de épocas adicionais. Um número insuficiente de épocas pode resultar em *underfitting*, enquanto épocas em excesso podem causar *overfitting*.

- **Tamanho do batch (16, 32, 64):** O tamanho do batch afeta a estimativa do gradiente durante o treinamento. Batches menores introduzem mais ruído (efeito regularizador), enquanto batches maiores proporcionam estimativas mais estáveis, mas podem convergir para mínimos locais menos generalizáveis.
- **Taxa de aprendizado (0,001; 0,01; 0,05):** A taxa de aprendizado controla a magnitude das atualizações dos pesos. Valores muito baixos resultam em convergência lenta, enquanto valores muito altos pode causar divergência ou oscilações durante o treinamento.
- **Variante do modelo (nano vs. small):** O YOLOv8n-cls (*nano*) possui menos parâmetros e é mais rápido, enquanto o YOLOv8s-cls (*small*) tem maior capacidade de representação. Esta variação avalia o *trade-off* entre complexidade do modelo e desempenho.

6.3 Resultados da Variação — Classificação Binária

A Tabela 5 apresentam os resultados obtidos nos 8 experimentos do cenário binário:

Tabela 5: Resultados da variação de hiperparâmetros — classificação binária.

Experimento	Acurácia	Precisão	Revocação	F1	Espec.
base	0.920533	0.922160	0.920533	0.920191	0.874730
epochs_5	0.920533	0.922160	0.920533	0.920191	0.874730
epochs_20	0.923495	0.924847	0.923495	0.923201	0.881210
batch_16	0.919546	0.919730	0.919546	0.919420	0.895248
batch_64	0.918559	0.919510	0.918559	0.918294	0.880130
lr_0001	0.920533	0.922160	0.920533	0.920191	0.874730
lr_005	0.920533	0.922160	0.920533	0.920191	0.874730
modelo_s	0.926456	0.926561	0.926456	0.926366	0.906048

Nota: Execute `yolo_binario_hiperparametros.py` *para obter os valores. Os resultados também são salvos automaticamente em* `resultados_hiperparametros_binario.csv`.

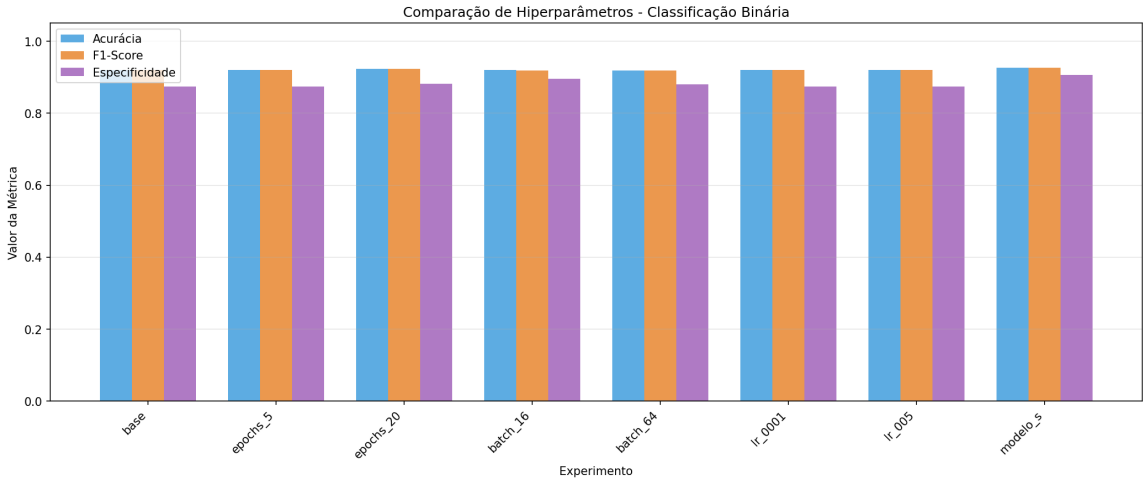

Figura 2: Comparação geral dos hiperparâmetros — classificação binária.

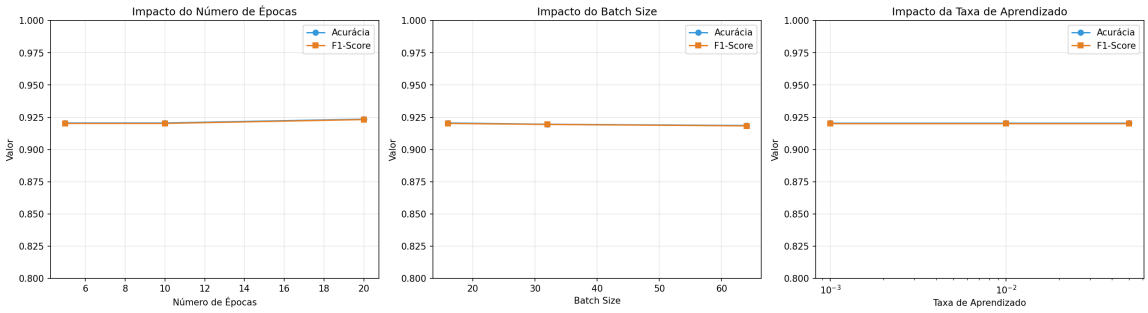

Figura 3: Impacto individual de cada hiperparâmetro — classificação binária.

6.4 Resultados da Variação — Classificação Multiclasse

A Tabela abaixo apresenta os resultados obtidos nos 8 experimentos do cenário multiclasse:

Tabela 6: Resultados da variação de hiperparâmetros — classificação multiclasse.

Experimento	Acurácia	Precisão	Revocação	F1	Espec. Méd.
base	0.823791	0.810327	0.823791	0.809436	0.950794
epochs_5	0.823791	0.810327	0.823791	0.809436	0.950794
epochs_20	0.832182	0.818056	0.832182	0.820760	0.955669
batch_16	0.821816	0.806538	0.821816	0.808147	0.951873
batch_64	0.829220	0.816419	0.829220	0.816076	0.953302
lr_0001	0.823791	0.810327	0.823791	0.809436	0.950794
lr_005	0.823791	0.810327	0.823791	0.809436	0.950794
modelo_s	0.846002	0.834399	0.846002	0.838300	0.961084

Nota: Execute `yolo_doencas_hiperparametros.py` *para obter os valores. Os resultados também são salvos em* `resultados_hiperparametros_doencas.csv`.

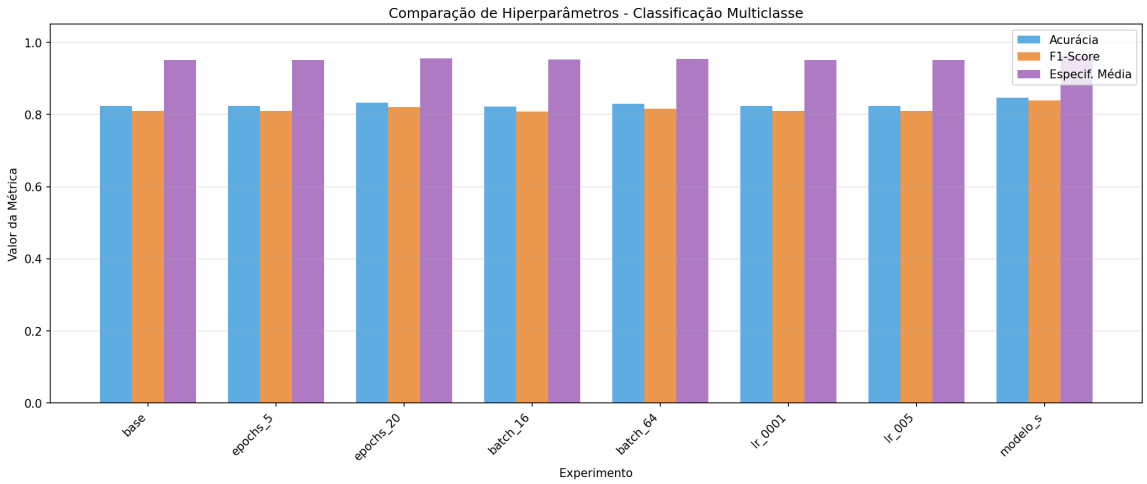

Figura 4: Comparação geral dos hiperparâmetros — classificação multiclasse.

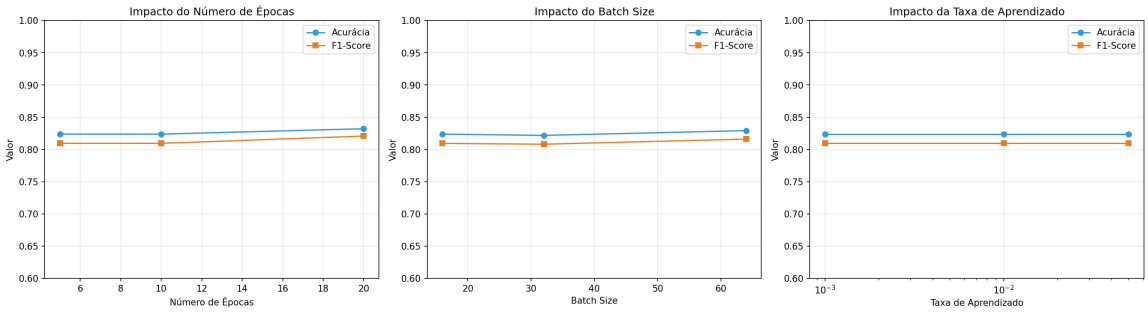

Figura 5: Impacto individual de cada hiperparâmetro — classificação multiclasse.

7 Resultados

7.1 Experimento 1: Classificação Binária (Normal vs. Anormal)

O primeiro experimento consistiu na classificação das células em duas categorias: Normal (correspondendo à subpasta Negativa) e Anormal (agrupando ASC-US, LSIL, ASC-H, HSIL e Carcinoma). A Tabela 7 apresenta as métricas obtida.

Tabela 7: Resultados do modelo YOLOv8 para classificação binária.

Métrica	**Valor**
Acurácia	0,9205
Precisão (weighted)	0,9222
Revocação (weighted)	0,9205
F1-Score (weighted)	0,9202
Especificidade	0,8747

O modelo atingiu uma acurácia de **92,05%**, demonstrando boa capacidade de distinguir entre células normais e anormais. A especificidade de 87,47% indica que o modelo classifica corretamente a grande maioria das células anormais, embora 12,5% das amostras anormais sejam erroneamente classificadas como normais (falsos negativos).

A Tabela abaixo apresenta a matriz de confusão obtida:

Tabela 8: Matriz de confusão — classificação binária.

	Pred. Anormal	**Pred. Normal**
Real Anormal	810	116
Real Normal	45	1.055

Dos 2.026 exemplos do conjunto de validação, 1.865 foram classificados corretamente. Foram observados 116 falsos negativos (amostras anormais classificadas como normais) e 45 falsos positivos (amostras normais classificadas como anormais).

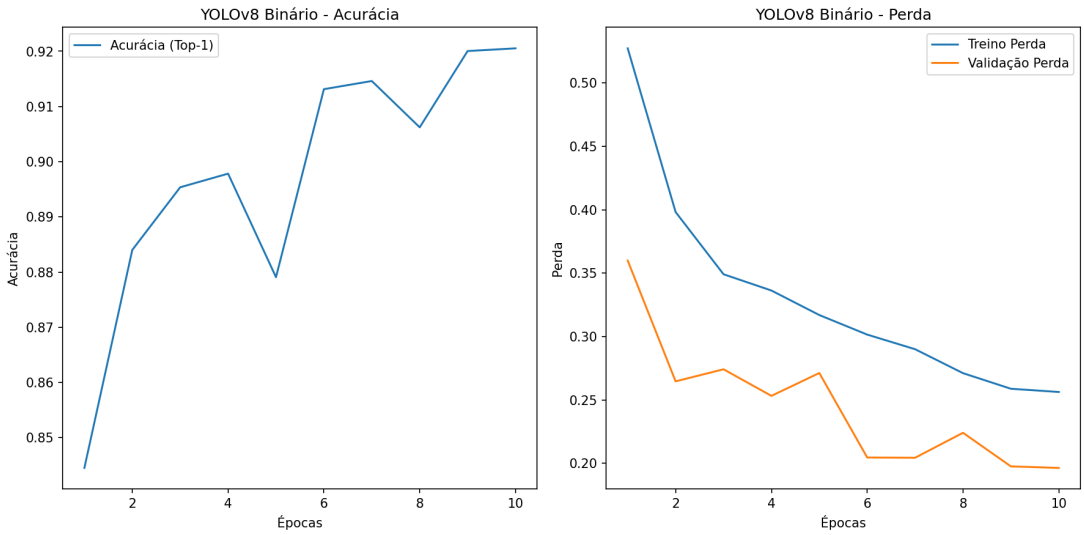

Figura 6: Curvas de acurácia e perda ao longo das épocas — classificação binária.

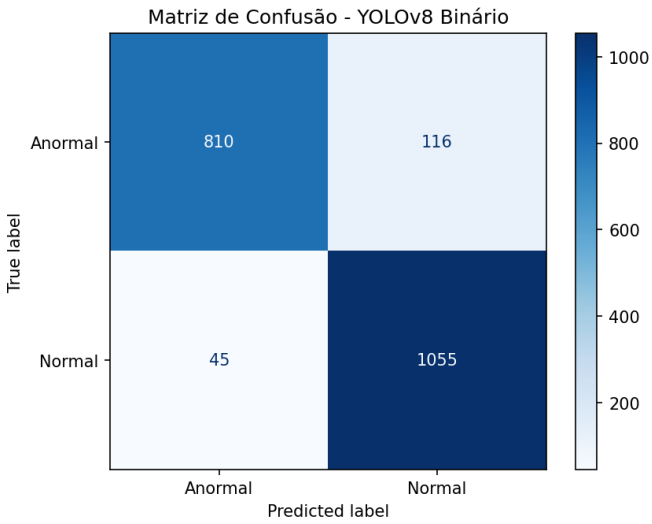

Figura 7: Matriz de confusão visualizada — classificação binária.

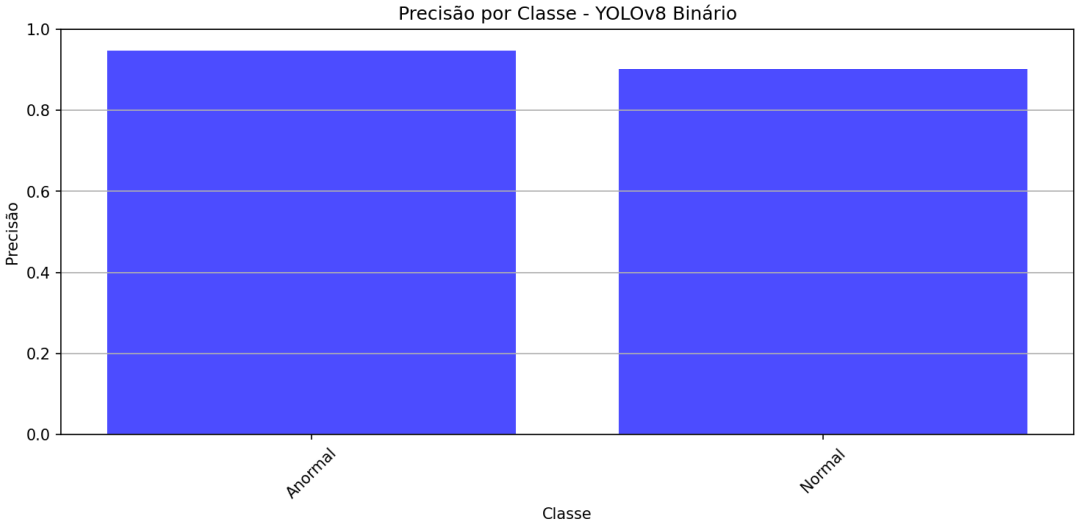

Figura 8: Precisão por classe — classificação binária.

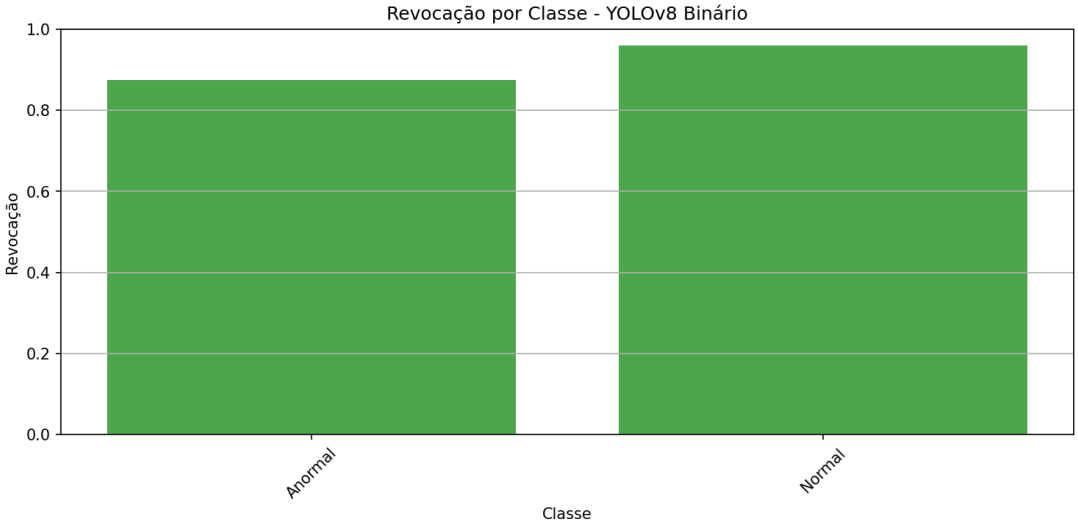

Figura 9: Revocação por classe — classificação binária.

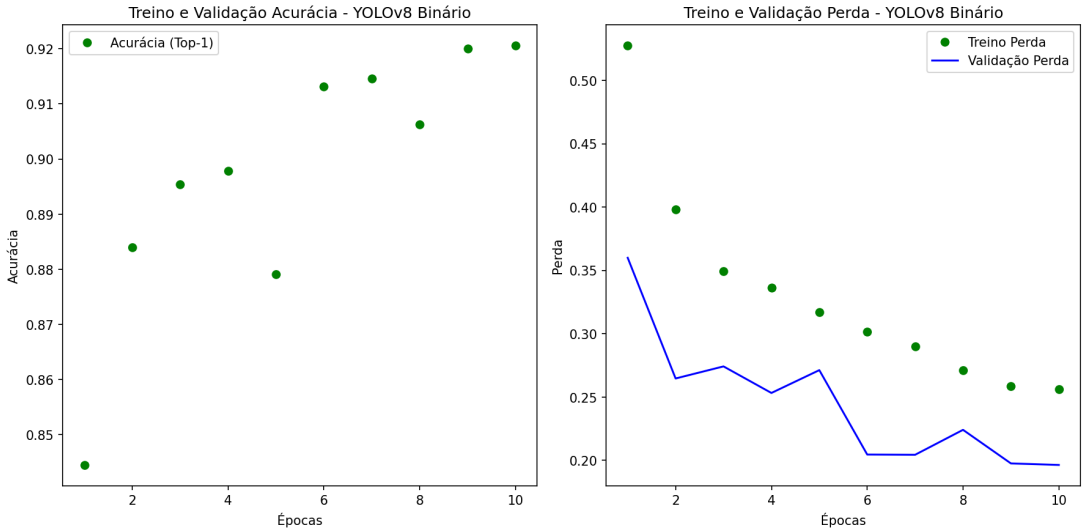

Figura 10: Convergência do treinamento — classificação binária.

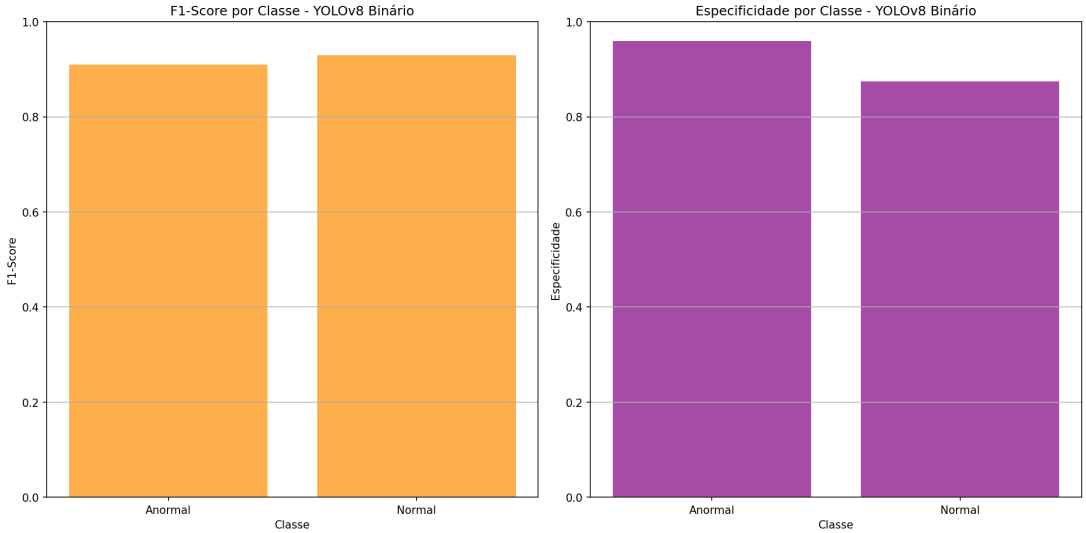

Figura 11: F1-Score e especificidade por classe — classificação binária.

7.2 Experimento 2: Classificação Multiclasse (6 Doenças)

O segundo experimento classificou as células nas 6 categorias diagnósticas originais. A Tabela 9 apresentam as métricas gerais obtidas.

Tabela 9: Resultados gerais do modelo YOLOv8 para classificação multiclasse.

Métrica	**Valor**
Acurácia	0,8238
Precisão (weighted)	0,8103
Revocação (weighted)	0,8238
F1-Score (weighted)	0,8094

A acurácia de **82,38%** na classificação em 6 classes é inferior à obtida no cenário binário (92,05%), o que é esperado dado o aumento significativo da complexidade da tarefa e a semelhança morfológica entre determinadas classes de lesões.

A Tabela abaixo apresenta o relatório detalhado de classificação por classe:

Tabela 10: Relatório detalhado por classe — classificação multiclasse.

Classe	**Precisão**	**Revocação**	**F1-Score**	**Amostras**
ASC-H	0,80	0,68	0,73	182
ASC-US	0,52	0,26	0,35	124
HSIL	0,81	0,87	0,84	336
LSIL	0,77	0,57	0,66	260
Negativa	0,85	0,96	0,91	1.100
Carcinoma	0,75	0,50	0,60	24
Média (weighted)	**0,81**	**0,82**	**0,81**	**2.026**

A classe **Negativa** obteve o melhor desempenho (F1 = 0,91), o que é atribuído ao maior número de amostras disponíveis para treinamento (5.500 imagens). Em contrapartida, a classe **ASC-US** apresentou o pior desempenho (F1 = 0,35), com apenas 26% de revocação, indicando que a maioria das amostras desta classe foram classificada incorretamente. A classe **Carcinoma**, apesar de possuir apenas 24 amostras no conjunto de validação, obteve precisão de 75%, embora com revocação de apenas 50%.

A Tabela abaixo apresenta a especificidade calculada por classe:

Tabela 11: Especificidade por classe — classificação multiclasse.

Classe	**Especificidade**
ASC-H	0,9837
ASC-US	0,9848
HSIL	0,9592
LSIL	0,9757
Negativa	0,8035
Carcinoma	0,9980

As especificidades são elevadas para todas as classes (acima de 0,95), com exceção da classe Negativa (0,8035). Isto indica que, quando o modelo prediz que uma amostra *não* pertence a determinada classe, esta predição é altamente confiável. A menor especificidade da classe Negativa se deve ao fato de que várias amostras de outras classes são erroneamente classificadas como Negativa.

A Tabela abaixo apresenta a matriz de confusão completa:

Tabela 12: Matriz de confusão — classificação multiclasse.

	ASC-H	**ASC-US**	**HSIL**	**LSIL**	**Neg.**	**Carc.**
ASC-H	**123**	1	31	9	18	0
ASC-US	1	**32**	5	12	73	1
HSIL	12	1	**293**	9	18	3
LSIL	6	19	15	**148**	72	0
Negativa	11	8	7	13	**1061**	0
Carc.	0	0	11	0	1	**12**

A análise da matriz de confusão revela que as confusões mais frequentes ocorre entre:

- **ASC-US → Negativa:** 73 amostras de ASC-US foram classificadas como Negativa, correspondendo a 58,9% das amostras desta classe. Isto é clinicamente preocupante, pois representa falsos negativos.
- **LSIL → Negativa:** 72 amostras de LSIL foram incorretamente atribuídas à classe Negativa (27,7%).
- **ASC-H → HSIL:** 31 amostras de ASC-H foram classificadas como HSIL, o que é compreensível dada a semelhança morfológica entre estas lesões.

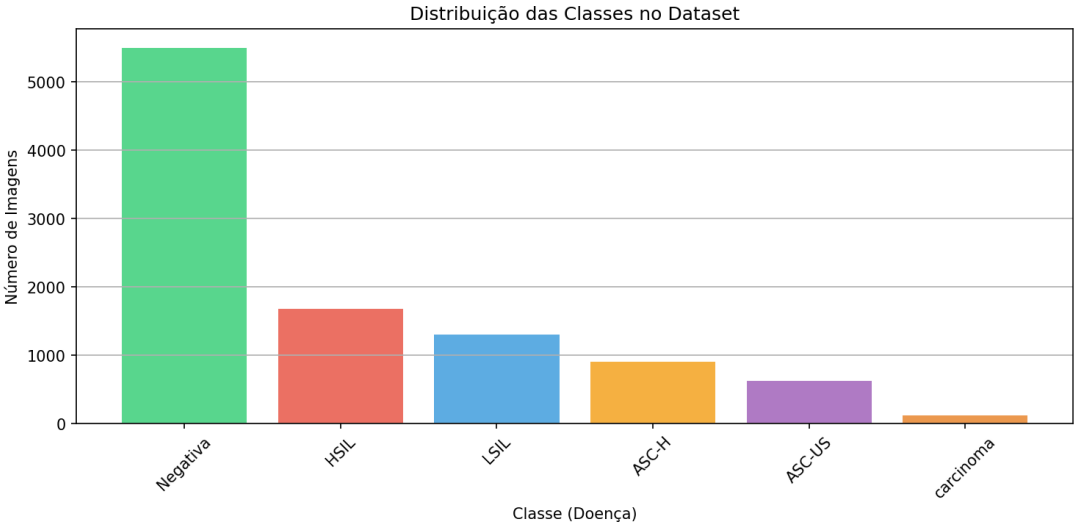

Figura 12: Distribuição das classes no dataset de treinamento.

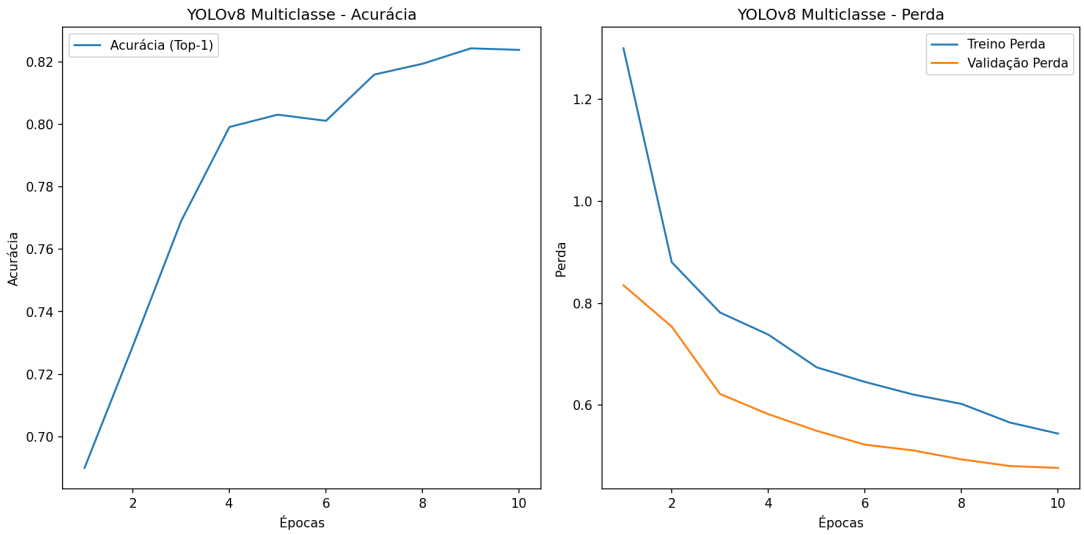

Figura 13: Curvas de acurácia e perda ao longo das épocas — classificação multiclasse.

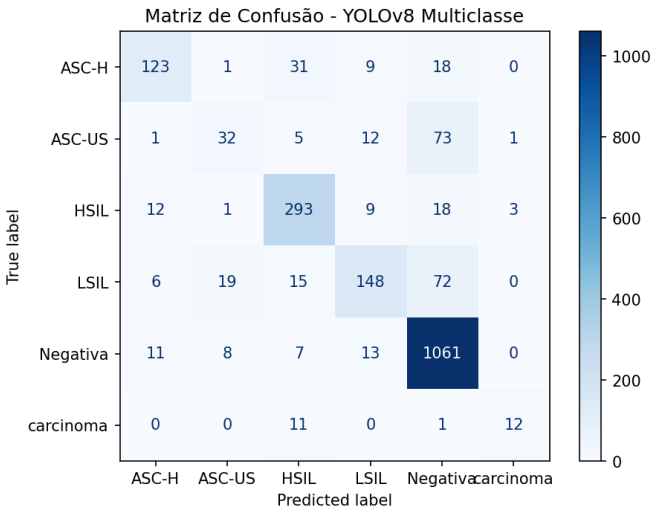

Figura 14: Matriz de confusão visualizada — classificação multiclasse.

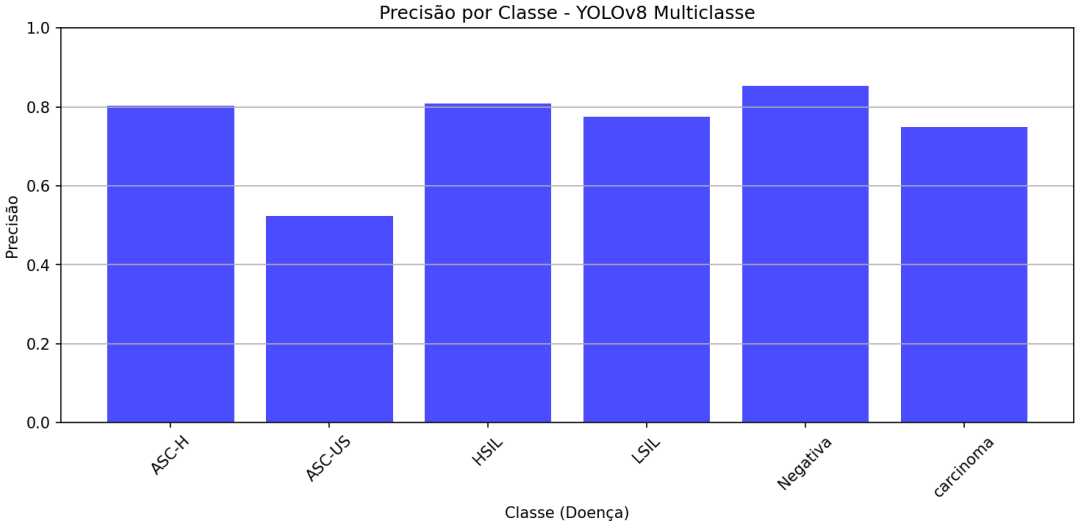

Figura 15: Precisão por classe — classificação multiclasse.

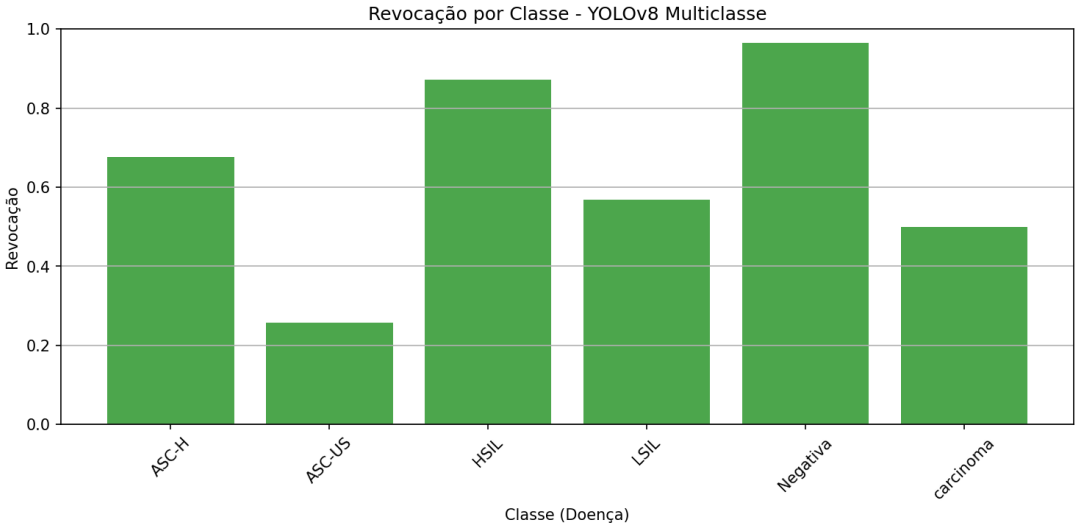

Figura 16: Revocação por classe — classificação multiclasse.

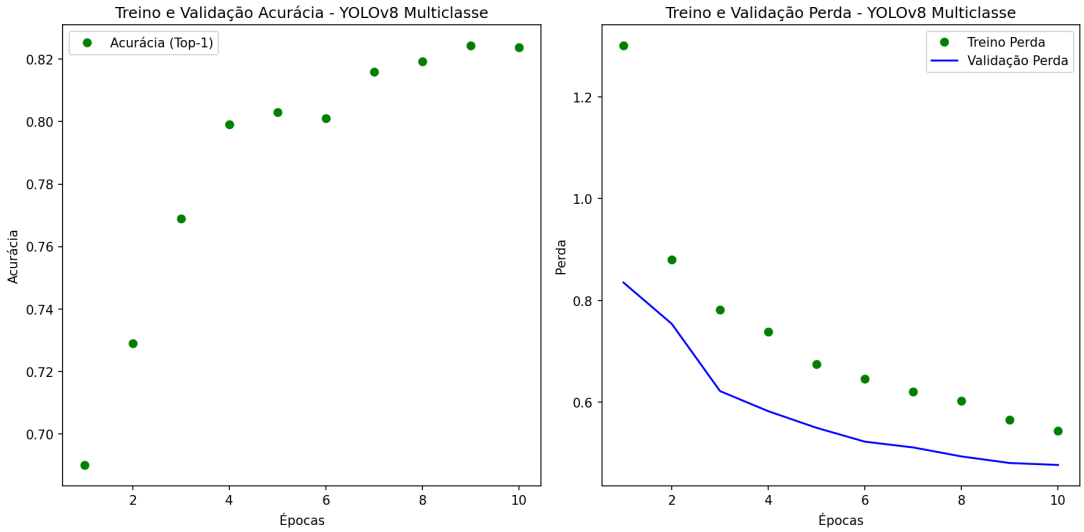

Figura 17: Convergência do treinamento — classificação multiclasse.

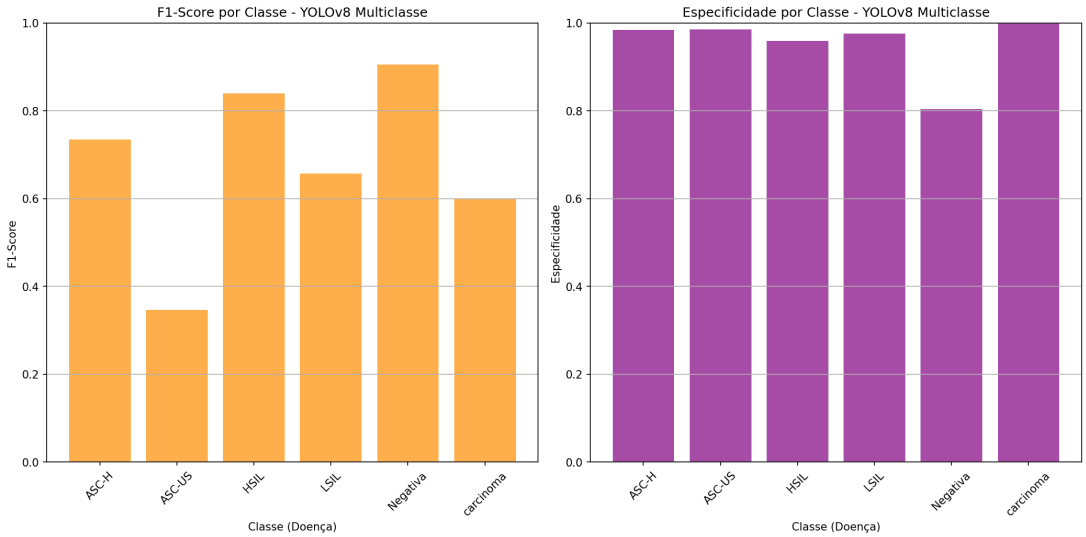

Figura 18: F1-Score e especificidade por classe — classificação multiclasse.

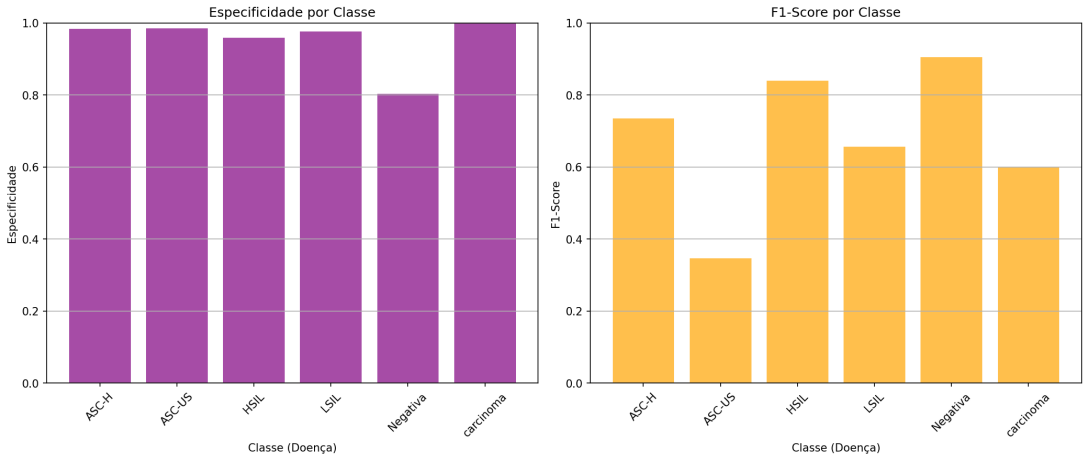

Figura 19: Especificidade e F1-Score por classe (comparativo) — classificação multiclasse.

7.3 Comparação entre os Experimentos

A Tabela abaixo sintetiza a comparação entre as duas abordagens experimentais.

Tabela 13: Comparação dos resultados entre classificação binária e multiclasse.

Métrica	**Binário (2 classes)**	**Multiclasse (6 classes)**
Acurácia	0,9205	0,8238
Precisão (weighted)	0,9222	0,8103
Revocação (weighted)	0,9205	0,8238
F1-Score (weighted)	0,9202	0,8094
Especificidade	0,8747	0,9508 (média)

Conforme esperado, o modelo binário apresenta resultados superiores em acurácia, precisão, revocação e F1-Score, uma vez que a tarefa de distinguir entre apenas duas classes é inerentemente mais simples. Entretanto, a classificação multiclasse fornece informação clínica substancialmente mais relevantes, possibilitando a identificação do tipo específico da lesão.

8 Discussão

8.1 Desempenho do YOLOv8 como Classificador

Os resultados demonstra que o YOLOv8 no modo *classify* é capaz de alcançar desempenho satisfatório na classificação de células cervicais, mesmo com imagens de baixa resolução (50×50 pixels) e um dataset moderadamente desbalanceado. A utilização de *transfer learning* a partir de pesos pré-treinados no ImageNet contribuiu significativamente para a convergência do modelo em apenas 10 épocas.

8.2 Impacto do Desbalanceamento

O desbalanceamento entre as classes apresentou impacto direto nos resultados, especialmente na classificação multiclasse. As classes com menor representação (ASC-US com 620 amostras e Carcinoma com 120 amostras) obtiveram revocação significativamente inferior às classes majoritárias. A classe ASC-US, com F1-Score de apenas 0,35, ilustra claramente este efeito: com apenas 124 amostras no conjunto de validação, o modelo não consegue aprender adequadamente os padrões discriminativos desta classe.

8.3 Confusões Clinicamente Relevantes

A análise da matriz de confusão multiclasse revela padrões de erro que possuem implicações clínicas importante:

- A confusão frequente entre ASC-US e Negativa (58,9% de falsos negativos) é a mais preocupante, pois implica que lesões de significado indeterminado podem não ser detectada pelo sistema.
- A confusão entre ASC-H e HSIL é menos crítica do ponto de vista clínico, pois ambas são lesões que requerem acompanhamento médico.

- A classe Carcinoma, embora com poucos exemplos, não foi confundida com a classe Negativa, o que é positivo para a triagem de casos graves.

8.4 Limitações

As principal limitações identificadas neste trabalho incluem:

- A resolução das imagens (50×50 pixels) é relativamente baixa para a análise citológica, podendo limitar a capacidade do modelo de capturar detalhes morfológicos sutis.
- O número de épocas (10) pode ser insuficiente para a convergência completa do modelo, especialmente no cenário multiclasse.
- O desbalanceamento severo entre as classes não foi tratado com técnicas específicas como *oversampling* ou pesos de classe.

9 Implementação

Todo o código foram desenvolvido integralmente pelo aluno, sem utilização de aplicações ou *pipelines* prontos de classificação. A implementação consiste em dois scripts Python independentes, conforme descrito na Tabela 14.

Tabela 14: Descrição dos arquivos de implementação.

Arquivo	**Descrição**
`yolo_binario.py`	Classificação binária (Normal vs. Anormal) utilizando YOLOv8. Inclui reorganização dos dados, treinamento com *transfer learning*, avaliação de métricas e geração de 6 gráficos salvos em PNG.
`yolo_doencas.py`	Classificação multiclasse (6 doenças) utilizando YOLOv8. Inclui reorganização com 6 classes, treinamento, relatório detalhado por classe, especificidade por classe e geração de 8 gráficos.

9.1 Bibliotecas Utilizadas

Tabela 15: Bibliotecas e suas respectivas funções no projeto.

Biblioteca	**Utilização**
Ultralytics (YOLOv8)	Treinamento e inferência do modelo de classificação
scikit-learn	Métricas de avaliação e divisão estratificada dos dados
NumPy	Manipulação de arrays numéricos
Pandas	Leitura do histórico de treinamento (CSV)
Matplotlib	Geração de gráficos e visualizações
shutil	Cópia de arquivos para reorganização do dataset

10 Conclusão

O presente trabalho demonstrou a viabilidade da utilização do YOLOv8 no modo *classify* para a classificação automática de células cervicais provenientes de exames de Papanicolaou. Foram conduzidos dois experimentos complementares:

1. Uma **classificação binária** (Normal vs. Anormal) que alcançou acurácia de 92,05%, F1-Score de 0,92 e especificidade de 87,47%, demonstrando eficácia como ferramenta de triagem inicial.

2. Uma **classificação multiclasse** em 6 categorias diagnósticas que obteve acurácia de 82,38% e F1-Score ponderado de 0,81, com destaque para o desempenho da classe HSIL (F1 = 0,84) e Negativa (F1 = 0,91), e com desempenho inferior para ASC-US (F1 = 0,35) devido ao desbalanceamento e semelhança morfológica.

A variação do hiperparâmetro principal — o número de classes de saída (2 vs. 6) — produziu diferenças significativas nos resultados, evidenciando o *trade-off* entre granularidade diagnóstica e desempenho do modelo. O uso de *transfer learning* a partir de pesos pré-treinados no ImageNet mostrou-se eficaz para a convergência rápida do modelo mesmo com um dataset de tamanho moderado.

Como trabalhos futuros, sugere-se: (i) a aplicação de técnicas de *data augmentation* para mitigar o desbalanceamento; (ii) o uso de pesos de classe durante o treinamento; (iii) o aumento da resolução das imagens de entrada; (iv) a exploração de variantes maiores do YOLOv8 (small, medium, large) para avaliar o impacto da capacidade do modelo; e (v) o aumento do número de épocas de treinamento.